神经网络与深度学习第一次作业

计科一班 陈杨 201730612499

O、课堂作业

1. 梯度下降法中:求E(w,b)对w和b的偏导

$$E(w,b) = MSE = \frac{1}{2m} \sum_{i=1}^{m} (y^{(i)} - f(x^{(i)}))^{2}$$

$$\frac{\partial E(w,b)}{\partial w} = \frac{\partial}{\partial w} \frac{1}{2m} \sum_{i=1}^{m} (y^{(i)} - f(x^{(i)}))^{2}$$

$$= \frac{1}{2m} \sum_{i=1}^{m} \frac{\partial}{\partial w} (y^{(i)} - f(x^{(i)}))^{2}$$

$$= \frac{1}{2m} \sum_{i=1}^{m} 2 * (y^{(i)} - f(x^{(i)})) * \frac{\partial}{\partial w} (y^{(i)} - f(x^{(i)}))$$

$$= \frac{1}{m} \sum_{i=1}^{m} (y^{(i)} - f(x^{(i)})) * (-x^{(i)})$$

$$= \frac{1}{m} \sum_{i=1}^{m} (f(x^{(i)}) - y^{(i)}) * x^{(i)}$$

$$\frac{\partial E(w,b)}{\partial b} = \frac{\partial}{\partial b} \frac{1}{2m} \sum_{i=1}^{m} (y^{(i)} - f(x^{(i)}))^{2}$$

$$= \frac{1}{2m} \sum_{i=1}^{m} \frac{\partial}{\partial b} (y^{(i)} - f(x^{(i)}))^{2}$$

$$= \frac{1}{2m} \sum_{i=1}^{m} 2 * (y^{(i)} - f(x^{(i)})) * \frac{\partial}{\partial b} (y^{(i)} - f(x^{(i)}))$$

$$= \frac{1}{m} \sum_{i=1}^{m} (y^{(i)} - f(x^{(i)})) * \frac{\partial}{\partial b} (y^{(i)} - wx^{(i)} - b)$$

$$= \frac{1}{m} \sum_{i=1}^{m} (y^{(i)} - f(x^{(i)})) * (-1)$$

$$= \frac{1}{m} \sum_{i=1}^{m} (f(x^{(i)}) - y^{(i)})$$

2. 最小二乘法中:求 $\frac{dE(W)}{dW}=0$ 的解析解

$$E(W) = \frac{1}{m} \sum (y - W^T X)^2 = \frac{1}{m} (y - WX)^T (y - WX)$$

$$E(W) = \frac{1}{m} (y - WX)^{T} (y - WX)$$

$$= \frac{1}{m} (y^{T} - X^{T}W^{T})(y - WX)$$

$$= \frac{1}{m} (y^{T}y - y^{T}WX - X^{T}W^{T}y + X^{T}W^{T}WX)$$

$$= \frac{1}{m} (y^{T}y - 2X^{T}W^{T}y + X^{T}W^{T}WX)$$

$$\frac{dE(W)}{dW} = \frac{d(y^{T}y - 2X^{T}W^{T}y + X^{T}W^{T}WX)}{dW}$$

$$= \frac{d(X^{T}W^{T}WX - 2X^{T}W^{T}y)}{dW}$$

$$= \frac{d(X^{T}W^{T}WX)}{dW} - 2X^{T}y$$

$$= (X^{T}X + X^{T}X)W - 2X^{T}y$$

$$= 2(X^{T}XW - X^{T}y)$$

令 $\frac{dE(W)}{dW}=0$,得

$$2(X^TXW - X^Ty) = 0$$

$$\Rightarrow X^TXW = X^Ty$$

$$\Rightarrow W = (X^TX)^{-1}X^Ty$$

一、Numpy基本操作

1. 导入numpy库

import numpy as np

2. 建立一个一维数组a, 初始化为[4, 5, 6]

a = np.array([4, 5, 6])

(1) 输出a的类型(type)


print(type(a))

(2) 输出a的各维度大小(shape)

print(a.shape)

(3) 输出a的第一个元素

print(a[0])



3. 建立一个二维数组b, 初始化为[[4, 5, 6], [1, 2, 3]]


```
b = np.array([[4, 5, 6], [1, 2, 3]])
```

(1)输出b的各维度大小(shape)

```
print(b.shape)
```

(2) 输出b[0, 0], b[0, 1], b[1, 1]这三个元素

```
print(b[0, 0], b[0, 1], b[1, 1])
```



4. 建立矩阵

(1) 建立一个大小为3×3的全0矩阵c

```
c = np.zeros((3, 3))
```

(2) 建立一个大小为4×5的全1矩阵d

```
d = np.ones((4, 5))
```

(3) 建立一个大小为4×4的单位矩阵e

```
e = np.eye(4)
```

5. 建立一个数组f, 初始化为[0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11] (arange)

```
f = np.arange(12)
```

(1) 输出f以及f的各维度大小

```
print(f)
print(f.shape)
```

(2) 将f的shape改为3×4(reshape)

```
f = f.reshape(3, 4)
```

(3) 输出f以及f的各维度大小

```
print(f)
print(f.shape)
```

(4) 输出f第二行(f[1,:])

```
print(f[1, :])
```

(5) 输出f最后两列(f[:, 2:4])

```
print(f[:, 2:4])
```

(6) 输出f第三行最后一个元素(使用-1表示最后一个元素)

print(f[2, :][-1])


二、Tensorflow练习


1. 线性回归

(1) 生成训练数据数据为带有服从0.5到-0.5的均匀分布噪声的正弦函数,代码如下:

```
num_observations = 100
x = np.linspace(-3, 3, num_observations)
y = np.sin(x) + np.random.uniform(-0.5, 0.5, num_observations)
```

画出这100个样本的散点图。





(2) 使用tensorflow实现线性回归模型,训练参数w和b。

$$y = w * x + b$$

• 导入模块、生成数据、定义训练集和参数

```
# 导入必需的numpy、tensorflow、matplotlib模块,处理v1和v2以避免兼容问题 import numpy as np import tensorflow.compat.v1 as tf import matplotlib.pyplot as plt
```

```
# 生成100组带有服从0.5到-0.5的均匀分布噪声的正弦函数数据
num_observations = 100
x = np.linspace(-3, 3, num_observations)
y = np.sin(x) + np.random.uniform(-0.5, 0.5, num_observations)
n = len(x)

# 定义学习率、迭代次数
learning_rate = 0.01
training_epochs = 1000
```

• 定义模型和模型参数

```
# 定义运行时接受训练数据的占位符
X = tf.placeholder("float")
Y = tf.placeholder("float")

# 定义模型参数
W = tf.Variable(np.random.randn(), name="w")
b = tf.Variable(np.random.randn(), name="b")

# 定义模型、损失函数、优化算法
y_pred = tf.add(tf.multiply(X, W), b)
cost = tf.reduce_sum(tf.pow(y_pred - Y, 2)) / (2 * n)
optimizer = tf.train.GradientDescentOptimizer(learning_rate).minimize(cost)
```


初始化

```
# 初始化所有变量
init = tf.global_variables_initializer()
```

• 开始训练

• 图形化训练集和训练结果

(3) 输出参数w、b和损失。




由输出结果可知最终损失为0.119,参数分别为w=0.332、b=-0.002。

即最终回归方程为: y = 0.332x - 0.002。

(4) 画出预测回归曲线以及训练数据散点图,对比回归曲线和散点图并分析原因。

Linear Regression Result



对比原始数据散点图以及训练得到的回归曲线,可以看出回归曲线并不能反映数据分布。原因在于选取了不合适的函数模型进行拟合,不应使用一次函数拟合正弦函数,应尝试使用其他函数模型进行线性回归。

2. 线性回归(使用多项式函数对原始数据进行变换)

(1)生成训练数据,数据同上。

(2)使用tensorflow实现线性回归模型,这里我们假设y是x的三次多项式,那么我们可以将数据拓展为: x、 x^2 、 x^3 三维数据,此时模型变为:


$$y = w_1 * x + w_2 * x^2 + w_3 * x^3 + b$$

(3)训练模型并输出参数 w_1 、 w_2 、 w_3 、b和损失。

• 在之前的代码中新添参数并作小幅修改

```
# 增添参数w_2和w_3、修改模型为多项式
w_2 = tf.Variable(np.random.randn(), name="w2")
y_pred = tf.add(tf.multiply(tf.pow(X, 2), w_2), y_pred)
w_3 = tf.Variable(np.random.randn(), name="w3")
y_pred = tf.add(tf.multiply(tf.pow(X, 3), w_3), y_pred)
```

• 输出参数和损失




由输出结果可知最终损失为0.073,参数分别为 $w_1=0.714,\ w_2=-0.020,\ w_3=-0.063,\ b=-0.153$ 。

即最终回归方程为: $y = 0.714x - 0.020x^2 - 0.063x^3 - 0.153$ 。

(4)画出预测回归曲线以及训练数据散点图,对比回归曲线和散点图并分析原因。

Linear Regression Polynomial Result



对比原始数据散点图以及训练得到的回归曲线,可以看出回归曲线能够较好地反映数据分布,但是损失函数得到的最终损失还是不够小,原因在于初始参数或模型欠佳。或许需要尝试调整学习率等初始化参数、改变优化算法、更换函数模型等,以使回归模型更贴合训练数据。

3. Softmax分类

(1)获取MNIST数据集,每张图片像素为28×28。

```
# 获取MNIST数据集
from tensorflow.examples.tutorials.mnist import input_data
mnist = input_data.read_data_sets("MNIST_data/", one_hot=True)
```

(2)模型架构为:

$$y = softmax(w * x + b)$$

其中w的维度为784×10,b的维度为10。

• 定义计算图

定义图像参数、学习率、训练次数 num_features = 784 num_labels = 10 learning_rate = 0.05 batch_size = 128 num_steps = 5001 # 定义输入图像数据 train_dataset = mnist.train.images

```
train_labels = mnist.train.labels
test_dataset = mnist.test.images
test_labels = mnist.test.labels
valid_dataset = mnist.validation.images
valid_labels = mnist.validation.labels
# 定义模型参数
graph = tf.Graph()
with graph.as_default():
   tf_train_dataset = tf.placeholder(
        tf.float32, shape=(batch_size, num_features))
    tf_train_labels = tf.placeholder(
       tf.float32, shape=(batch_size, num_labels))
    tf_valid_dataset = tf.constant(valid_dataset)
    tf_test_dataset = tf.constant(test_dataset)
    # 定义Softmax模型参数
    weights = tf.Variable(tf.truncated_normal([num_features, num_labels]))
    biases = tf.Variable(tf.zeros([num_labels]))
    # 定义损失函数(交叉熵)
    logits = tf.matmul(tf_train_dataset, weights) + biases
    loss = tf.reduce_mean(tf.nn.softmax_cross_entropy_with_logits()
       labels=tf_train_labels, logits=logits))
    # 定义优化模型(梯度下降)
    optimizer = tf.train.GradientDescentOptimizer
               (learning_rate).minimize(loss)
   # 训练、验证、测试预测
    train_prediction = tf.nn.softmax(logits)
   valid_prediction = tf.nn.softmax(
       tf.matmul(tf_valid_dataset, weights) + biases)
    test_prediction = tf.nn.softmax(
       tf.matmul(tf_test_dataset, weights) + biases)
# 定义准确率
def accuracy(predictions, labels):
    correctly_predicted = np.sum(
        np.argmax(predictions, 1) == np.argmax(labels, 1))
    accu = (100.0 * correctly_predicted) / predictions.shape[0]
    return accu
```

• 开始训练

```
with tf.Session(graph=graph) as session:

# 初始化

tf.global_variables_initializer().run()

# 进行每趟训练

for step in range(num_steps):

# 随机生成偏移量

offset = np.random.randint(0, train_labels.shape[0] - batch_size - 1)
```

• 输出准确率


```
finalLoss = session.run(loss, feed_dict=feed_dict)
finalAccuracy = accuracy(test_prediction.eval(), test_labels)

print("\nLoss: {}".format(finalLoss))
print("Test accuracy: {:.1f}%".format(finalAccuracy))
```

• 画图


```
# 损失随迭代次数变化图
plt.figure()
plt.plot(figurex, figurey1)
plt.title("Loss along the iterate times")
plt.xlabel("Iterate times")
plt.ylabel("Loss")
plt.savefig("loss.png")


# 准确率随迭代次数变化图
plt.figure()
plt.plot(figurex, figurey2)
plt.title("Accuracy along the iterate times")
plt.xlabel("Iterate times")
plt.ylabel("Accuracy")
plt.savefig("accuracy.png")
```




由输出结果可知最终损失为0.436,准确率为85.6%。

(3)画出训练和测试过程的准确率随迭代次数变化图,画出训练和测试过程的损失随迭代次数变化图。





Accuracy along the iterate times



随着迭代次数的增加,损失逐渐下降,准确率逐渐上升。且在迭代次数较少时,损失和准确率随迭代次数变化的变化率较大,随后变化率逐渐减少并趋于平缓。